

未来互联网新技术 课程项目说明

项目名称： 多模态模型攻击评估平台的设计与实现

项目编号： _____

项目成员： _____

二〇二六年四月

一、系统要求

(一) 项目概述

本项目面向多模态大模型快速发展背景下的安全需求，围绕图文理解、视觉问答、图像描述等典型任务，开展多模态模型攻击方法与安全评估技术研究。项目拟构建一个集攻击样本生成、对抗扰动优化、攻击效果验证、鲁棒性分析与结果展示于一体的多模态模型攻击实验平台，重点研究图像扰动攻击、文本提示攻击、语音指令攻击以及黑盒迁移攻击等关键技术之一。

系统以主流多模态模型为研究对象，结合视觉编码、文本编码、跨模态对齐与推理机制，探索多模态模型在复杂输入条件下的脆弱性表现，分析单一模态攻击方式对模型输出一致性、语义对齐能力和安全性的影响，形成一套可复现实验流程与评估方案。

(二) 技术要求

以构建“多模态模型攻击与安全评估平台”为目标，重点完成攻击场景设计、攻击样本构造、攻击算法实现、实验评估分析、可视化展示等功能模块，以适应人工智能安全研究对模型脆弱性验证、攻击过程可控化、实验流程标准化和结果分析系统化的需求。各项目小组可结合自身选题与实现条件，自主选择图像、文本、语音、视频等模态的任意一种模态开展实现。具体内容如下：

1. 攻击场景设计

围绕图像分类、图文检索、视觉问答、图像描述、视频生成等典型模态任务，设计多种攻击实验场景。根据输入形式与任务特点，构建图像扰动攻击、文本诱导攻击、图片攻击、音视频攻击等测试环境。

2. 多模态数据集与样本管理

对实验所需的图像、文本提示词、问答对、标签信息等进行规范化管理，建立基础数据集与攻击样本集。支持样本导入、筛选、标注、版本管理和攻击前后结果对比，满足多轮实验和重复验证需求。

3. 攻击算法实现

基于多模态模型特征提取与跨模态对齐机制，各小组可任选以下一种实现方向开展系统设计与实验，包括但不限于：

基于梯度优化的图像对抗扰动生成；

基于提示注入的文本攻击；

基于数据扰动的大模型音视频理解偏差攻击；

面向未知模型的黑盒迁移攻击。

系统应能够输出攻击样本、扰动强度、攻击成功率等关键结果，并支持不同参数配置下的算法对比。

4. 攻击效果评估与鲁棒性分析

从攻击成功率、输出偏移程度、语义一致性破坏程度、迁移能力、查询次数和计算代价等维度建立评估指标体系。对不同模型、不同任务和不同攻击方法的实验结果进行统计分析，评估模型鲁棒性与攻击有效性。

5. 平台展示

设计实验平台前端展示界面，实现攻击配置、实验运行、结果查询、指标统计与可视化分析等功能。

（三）指标要求

（1）功能要求

1. 支持数据样本管理、攻击样本生成与实验记录存储功能；
2. 支持所选模态的攻击的实现与调用；
3. 支持对主流多模态模型开展攻击验证与结果评估；
4. 支持攻击结果统计分析和可视化展示功能；

（四）成果形式

（1）文档类

1. 算法说明 1 份；
2. 总结报告 1 份。